



Relatório CardioGoodFitness

Introdução:

Para realização da atividade prática, foi selecionada a base de dados presente no arquivo CardioGoodFitness.csv, o qual contém informações de 180 clientes de uma empresa que vende três modelos distintos de esteira: TM195, TM498 e TM798. Todas as análises foram feitas pelo aplicativo RStudio, e o código foi escrito na linguagem de programação R.

O objetivo deste trabalho foi de realizar uma análise descritiva e aplicar métodos estatísticos à base de dados, com o intuito de extrair informações relevantes que possam ser úteis à empresa a respeito dos seus clientes, e dessa forma, possibilitar para a empresa tomadas de decisões futuras embasadas mais assertivas para a comercialização de seus produtos.

Metodologia:

A base de dados do trabalho contém 180 linhas referentes às informações disponibilizadas pelos 180 clientes. Além disso, ela inclui 9 variáveis, detalhadas nas seguintes colunas:

- Product: Os 3 tipos de esteira - TM195, TM498, ou TM798.
- Age: Anos completos.
- Gender: Gênero - Masculino e Feminino.
- Education: Anos estudados.
- MaritalStatus: Estado civil - Solteiro ou casado.
- Usage: Número médio de vezes que o clientes planeja usar a esteira por semana.
- Fitness: Autoavaliação da aptidão física em uma escala de 1 a 5, onde 1 é má forma e 5 é excelente.
- Income: Renda familiar anual.
- Miles: Número médio de milhas que o cliente espera caminhar/correr a cada semana.

As variáveis Product, Gender e MaritalStatus são qualitativas nominais, enquanto as variáveis Age, Education

A aplicação dos métodos estatísticos começaram com análises gerais das variáveis presentes na base de dados, utilizando a função “summary()”, para obter uma rápida visão panorâmica dos dados. Essa função forneceu informações da classe, modo e número de elementos nas colunas das variáveis qualitativas. Para as variáveis quantitativas, foram apresentados o valor mínimo, 1º quartil, média, mediana, 3º quartil, valor máximo e número de valores ausentes (NA), se houver. Além disso, foi construído um mapa de calor da matriz de correlação para avaliar o grau de correlação entre as variáveis e como elas influenciam umas às outras.

Após o panorama inicial, foram realizadas análises mais concentradas de algumas variáveis, utilizando tabelas e gráficos para entender seus atributos e características em relação aos clientes. As análises foram conduzidas tanto de forma univariada, focando em uma variável de cada vez, quanto de forma multivariada, para explorar as relações entre essas diferentes variáveis. Tabelas de frequência absoluta e relativa, além de gráficos de setores, barras, histogramas e boxplots, foram utilizados para entender as distribuições, identificar padrões e avaliar a simetria dos dados. Com as tabelas e gráficos construídos, foi possível uma compreensão mais clara e detalhada dos dados.

Resultados:

Análise Geral dos Dados

A função “summary()” revelou os seguintes resultados organizadas nas seguintes tabelas:

Tabela 1: Tabela das variáveis qualitativas			
Estatística	Product	Gender	MaritalStatus
Length	180	180	180
Class	character	character	character
Mode	character	character	character

A Tabela 1 apresenta as informações extraídas da função summary() para as variáveis qualitativas Product, Gender e MaritalStatus. A tabela mostra que o Length de cada variável é 180, indicando que há 180 observações, correspondentes ao número total de clientes entrevistados. Todas as três variáveis têm Class e Mode definidos como character, o que significa que seus valores são textuais e representam categorias.

Tabela 2: Tabela das variáveis quantitativas						
Estatística	Age	Education	Usage	Fitness	Income	Miles
Min	18.00	12.00	2.00	1.00	29,562	21.0
1st Qu	24.00	14.00	3.00	3.00	44,059	66.0
Median	26.00	16.00	3.00	3.00	50,597	94.0
Mean	28.79	15.57	3.46	3.31	53,72	103.2
3rd Qu	33.00	16.00	4.00	4.00	58,668	114.8
Max	50.00	21.00	7.00	5.00	104,581	360.0

Já na Tabela 2 estão alguns dados referentes às variáveis quantitativas Age, Education, Usage, Fitness, Income e Miles. O que cada linha representa e outras informações mais importantes são discutidas abaixo:

- 1) Age: A idade mínima dos clientes é de 18 anos (valor referente a “Min”) e essa variável varia até no máximo 50 anos (Max), a média é de 28,79 anos (Mean). Tendo em vista os valores referentes a média e do primeiro, segundo e terceiro quartil, (1st Qu, Median e 3rd Qu) pode-se dizer que a distribuição da idade é ligeiramente inclinada para a direita, já que a média é um pouco maior que a mediana (26 anos).
- 2) Education: Varia de 12 a 21 anos, os anos de estudo dos clientes se distribui ao entorno de 16 anos de educação (mediana). A média é 15,57 anos, indicando uma distribuição assimétrica mais concentrada entre 14 e 16 anos de escolaridade.
- 3) Usage: O número médio de vezes que o clientes planeja usar a esteira por semana variam vão de 2 a 7 dias por semana, com a maioria dos clientes se concentrando em valores entre 3 e 4 (1º quartil, mediana e 3º quartil). A média é de 3,46 de uso médio de dias na semana do produto.
- 4) Fitness: Com valores variando de 1 a 5, a variável Fitness também apresenta uma distribuição concentrada nos valores entre 3 e 4. A média de 3,31 reflete que a maioria dos clientes tem um nível moderado de aptidão física.
- 5) Income: A renda familiar dos clientes varia de 29.562 a 104.581, com a média de 53.720. A distribuição é mais ampla, e a mediana de 50.597 mostra que a maioria dos clientes tem rendimentos ligeiramente abaixo da média, e bem abaixo do valor máximo (104.581).
- 6) Miles: A variação do número médio de milhas que o cliente espera caminhar/correr a cada semana é de 21 a 360 milhas, com uma média de 103,2 milhas. A distribuição está mais concentrada entre 66 e 114,8 milhas (1º quartil a 3º quartil), mas há clientes que planejam caminhar/correr uma quantidade de milhas maiores, como o valor máximo de 360 milhas.

Na figura 1, está o mapa de calor da matriz de correlação:




Figura 1: Mapa de calor da matriz de correlação das variáveis quantitativas.

O mapa de calor da matriz de correlação serve para visualizar a relação entre as variáveis da base de dados a partir de um coeficiente que varia de -1 a 1 e uma cor que vai do azul para o vermelho. Em um mapa de calor, as cores que indicam uma forte correlação entre as variáveis são as cores quentes (como o vermelho) e coeficiente 1, enquanto as cores frias (como o azul) e um coeficiente -1 indicam correlações mais fracas. Esse tipo de visualização é útil para identificar rapidamente padrões e relações entre variáveis.

É possível observar algumas esperadas fortes correlações como por exemplo da variável Fitness com as variáveis Usage e Miles, isso ocorre porque quanto maior for a autoavaliação de aptidão física do cliente maior vai ser o número de dias que o cliente vai utilizar a esteira durante a semana e consequentemente maior serão as milhas percorridas.

Algumas conclusões não tão óbvias que podem ser tiradas do mapa de calor da matriz de correlação é a de tendência positiva considerável de 0.51 entre as variáveis Age e Income, o que aponta que quanto maior for a idade do cliente, há uma tendência de maior renda familiar anual. Além disso, é possível observar também uma tendência positiva entre as variáveis Education e as variáveis Fitness, Usage e Miles (Os quais já vimos anteriormente ter forte correlação entre elas). Expressando uma tendência de quanto maior for o nível de escolaridade do cliente, mais exercícios na esteira ele provavelmente fará.

Análise Univariada e Multivariada

Tabela 3: Tabela de frequência dos tipos de esteira		
Tipo de esteira	Frequência Absoluta	Frequência Relativa (%)
TM195	80	44,4
TM498	60	33,3
TM798	40	22,2




Figura 2: Gráfico em barras da distribuição do tipo de esteiras.

Pela tabela 2 e figura 2, podemos constatar que a esteira mais comprada é a esteira de modelo TM195, em segundo lugar vem a esteira de modelo TM498 e por último a TM798.




Figura 3: Boxplot de milhas por tipo de esteira.

A esteira TM195 apresenta uma distribuição de milhas mais compacta e assimétrica, a maioria dos clientes pretendem percorrer entre 50 e 150 milhas, observa-se alguns outliers que passam das 150 milhas. Já no modelo TM498, seus limites de milhas estão bem próximos do modelo TM195, no entanto, os dados estão mais dispersos, e com maior simetria, esse modelo também apresenta milhas acima de 150. No boxplot do modelo TM798 apresenta uma mediana significativamente maior, em torno de 200 milhas, e uma maior dispersão que os outros dois modelos, com a maioria dos dados variando entre 100 até 350 milhas, o que sugere que os clientes que compraram essa esteira alcançam percorrer distâncias mais longas, esse boxplot é o mais simétrico. O modelo TM798 apresenta o outlier mais alto, esse cliente pode estar representando um atleta.

Tabela 4: Tabela de frequências do gênero dos clientes		
Gênero	Frequência Absoluta	Frequência Relativa (%)
Feminino	76	42.2
Masculino	104	57.8

Gráfico de setores referente ao gênero dos clientes




Figura 5: Gráfico de setores do gênero dos clientes.

Tabela 5: Tabela de frequências do estado civil		
Gênero	Frequência Absoluta	Frequência Relativa (%)
Casado	107	59.4
Solteiro	73	40.6

Tabela 6: Tabela de frequências do número médio de vezes que o clientes planeja usar a esteira por semana.

Dias de Uso	Frequência Absoluta	Frequência Relativa (%)
2	33	18.30
3	69	38.30
4	52	28.90
5	17	9.44
6	7	3.89
7	2	1.11

Tabela 7: Tabela de frequências da autoavaliação da aptidão física.

Dias de Uso	Frequência Absoluta	Frequência Relativa (%)
1	2	1.11
2	26	14.40
3	97	53.90
4	24	13.30
5	31	17.20




Figura 6: gráfico de barras por idade do cliente

18-21	22-25	26-29	30-33	34-37	38-41	42-45	46-50
0.13	0.37	0.16	0.13	0.10	0.04	0.03	0.03

É possível perceber analisando o gráfico de barras e a tabela de frequência relativa que a maioria dos clientes se concentra na faixa etária de 22 a 25 anos, onde temos aproximadamente 37% dos compradores dos 3 tipos de esteiras, em conjunto pode ser feita a análise que após apresentar seu pico de compradores entre 22-25 anos nós temos uma relação inversa entre o número de clientes e sua idade, onde na faixa etária mais avançada do nosso banco de dados, ou seja, de 46 a 50 anos possuímos apenas 3% do número de clientes totais da empresa.

Após isso, foi realizado um teste de ANOVA, o qual foi aplicado para comparar as médias de três ou mais grupos, foi utilizado para comparar a média da renda dos clientes que adquiriram cada um dos três tipos de esteira, tendo como base em um nível de significância de 0,05. Esse teste avalia se pelo menos um dos grupos possui uma média significativamente diferente das demais. A hipótese nula, da qual diz que existirá uma igualdade entre as médias, é rejeitada quando o p-valor é menor que o nível de significância. No caso analisado, o p-valor obtido foi de $2e-16$, significativamente inferior a 0,05. Dessa forma, rejeita-se a hipótese nula, indicando que pelo menos um dos grupos apresenta uma média significativamente diferente, como é possível perceber analisando o gráfico abaixo.




Figura 7: Boxplot Renda familiar por esteira

Analisando o gráfico acima é possível perceber que a média que difere é a da esteira TM798 da qual também tem a maior dispersão entre a renda de seus compradores onde sua mediana se encontra por volta de 80000, já os outros tipos de esteiras tanto a TM195 e a TM498 apresentam uma menor dispersão entre a renda dos seus compradores e uma mediana entre 40000 e 60000, por fim é possível perceber que os valores da renda dos compradores da TM498 é relativamente maior do que dos compradores da TM195, analisando a assimetria conseguimos perceber uma clara assimetria negativa na TM498 e leves assimetrias negativas na TM195 e TM798.




Figura 8: Boxplot distribuição renda




Figura 9: Histograma distribuição de renda

A análise do histograma e do boxplot revela um número significativo de outliers, indicando uma elevada dispersão na distribuição da renda dos consumidores que adquirem as esteiras. Além disso, é possível observar uma assimetria positiva na distribuição, evidenciada e justificada pela presença de outliers em valores mais elevados de renda.




Figura 10: Histograma distancia percorrida em milhas




Figura 11: Boxplot distância percorrida em milhas

O histograma revela que a maioria das pessoas percorre distâncias próximas a 100 milhas, com a frequência diminuindo gradualmente para distâncias maiores. Distâncias superiores a 250 milhas são raras e podem representar casos fora do padrão. Esse fenômeno também pode ser observado no boxplot, que apresenta muitos outliers e uma mediana posicionada em torno de 100 milhas, reforçando a concentração dos dados nessa faixa.




Figura 12: Gráfico de barras estado civil e gênero

	Partnered	Single
Female	0.26	0.17
Male	0.34	0.24

A análise do gráfico acima revela que a maior parte dos compradores de esteiras é composta por indivíduos casados, com os homens casados representando a maior proporção entre os consumidores, correspondendo a 34% do total. Em seguida, as mulheres casadas e os homens solteiros aparecem com 26% e 24%, respectivamente. Por outro lado, o grupo com menor participação nas compras são as mulheres solteiras.




Figura 13: Grafico de barras faixa etaria por tipo de esteira

A análise do gráfico revela que a esteira mais popular entre os consumidores é a TM195, seguida pela TM498 e, por último, pela TM798. Em relação às esteiras TM195 e TM498, observa-se que a faixa etária predominante entre os compradores é a de 18 a 25 anos. No caso da TM798, nota-se

uma distribuição igualitária entre as faixas etárias de 18 a 25 anos e de 26 a 35 anos. Adicionalmente, pode-se observar uma maior proximidade entre os compradores da TM798 nas faixas etárias de 18 a 35 anos e de 36 a 45 anos.

Conclusão:

Com base na análise dos dados, é possível concluir que a maior parte dos consumidores está na faixa etária de 18 a 35 anos, com o pico de compradores concentrado entre 22 e 25 anos. De forma geral, observa-se que a maioria dos consumidores é composta por indivíduos casados, com uma renda predominante entre 40.000 e 60.000. Além disso, entre os três modelos de esteiras analisados, a TM195 se destaca como a mais vendida.

Uma recomendação viável seria concentrar os esforços na produção da TM195, assim como intensificar as ações de marketing voltadas para o público-alvo, ou seja, consumidores jovens e casados, que representam a maior parte das compras para todos os modelos de esteira.

No entanto, as limitações dessa análise estão relacionadas à ausência de algumas variáveis importantes no banco de dados, como informações sobre a saúde dos consumidores, incluindo peso, problemas cardíacos, entre outros. Apesar dessas limitações, a análise realizada forneceu percepções valiosas, que poderiam orientar uma empresa em suas estratégias para aumentar as vendas, com base nos dados disponíveis.

Apêndice:

[1] CardioGoodFitness | Cardio Good Fitness Case Study. Disponível em: <<https://www.kaggle.com/datasets/saurav9786/cardiogoodfitness>>.

Código:

```
library(readr)
library(dplyr)

dados <- read_csv("CardioGoodFitness.csv")

#Informações preliminares da base de dados (180 linhas 9 colunas/variáveis):

#Product: Os 3 tipos de esteira - TM195, TM498, ou TM798.
#Age: Anos completos.
#Gender: Gênero - Masculino e Feminino.
#Education: Anos estudados.
#MaritalStatus: Estado civil - Solteiro ou casado.
#Usage: Número médio de vezes que o clientes planeja usar a esteira por semana.
#Fitness: Autoavaliação da aptidão física em uma escala de 1 a 5, onde 1 é má forma e 5 é excelente.
#Income: Renda familiar anual.
#Miles: Número médio de milhas que o cliente espera caminhar/correr a cada semana.

#### Visualização Geral dos Dados ####

#Informações sintetizadas da base de dados
summary(dados)

#### Análise Multivariada dos Dados ####

# Calcular a matriz de correlação apenas para colunas numéricas
cor_matrix <- cor(dados[sapply(dados, is.numeric)], use = "complete.obs")

# Exibir a matriz de correlação
print(cor_matrix)

# Instalar o pacote (se necessário)
install.packages("corrplot")
# Carregar o pacote
library(corrplot)

#Mapa de calor
corrplot(cor_matrix, method = "color",
```

```

        col = colorRampPalette(c("blue", "white", "red"))(50),
        tl.col = "black",      # Cor dos rótulos das variáveis
        addCoef.col = "black", # Adicionar valores das correlações
        number.cex = 0.7,     # Tamanho dos números
    )
    title("Mapa de Calor da Matriz de Correlação", line = 1.0)

# Exibir a matriz de correlação
print(cor_matrix)

#### Análise Univariada dos Dados ####

#Análise da frequência absoluta e relativa do tipo de esteira:
tab_freq_Product <- dados %>%
  count(Product) %>% # Conta a frequência absoluta
  mutate(freq_rel_Product = (n / sum(n))*100) # Calcula a frequência relativa

#Visualização da tabela de frequências do tipo de esteira
tab_freq_Product

#Gráfico de Barras do tipo de esteira
barplot(table(dados$Product),
  main = "Distribuição de frequência por tipo de produto de esteira",
  ylab = "No. dos de esteiras",
  xlab = "Tipos de esteiras")

#Gráfico de setores do tipo de esteira
pie(table(dados$Product),
  main = 'Gráfico de setores das frequências dos tipos de produtos de esteira',
  radius = 1.0
)

#Boxplot de Milhas que o cliente espera percorrer a cada semana por cada Tipo de Esteira
boxplot(dados$Miles~dados$Product,
  main = "Boxplot de milhas que o cliente espera percorrer na semana
  por cada Tipo de Esteira",
  ylab = "Milhas",
  xlab = "Tipo de Esteira", col = c("grey"))

#Análise da frequência absoluta e relativa do sexo dos clientes:
tab_freq_Gender <- dados %>%
  count(Gender) %>% # Conta a frequência absoluta
  mutate(freq_rel_Gender = (n / sum(n))*100) # Calcula a frequência relativa

tab_freq_Gender

```

```
#Gráfico de setores referente ao gênero dos clientes
pie(table(dados$Gender),
  main = 'Gráfico de setores referente ao gênero dos clientes',
  radius = 2.0
)
```

```
#Análise da frequência absoluta e relativa dos anos de estudo do cliente:
tab_freq_Education <- dados %>%
  count(Education) %>% # Conta a frequência absoluta
  mutate(freq_rel_Education = (n / sum(n))*100) # Calcula a frequência relativa
```

```
tab_freq_Education
```

```
#Milhas que o cliente espera percorrer a cada semana em cada Tipo de Esteira
boxplot(dados$Age~dados$Gender,
  main = "Milhas que o cliente espera percorrer na semana
  em cada Tipo de Esteira",
  ylab = "Idade",
  xlab = "Gênero", col = c("blue"))
```

```
#Análise da frequência absoluta e relativa do estado civil dos clientes:
tab_freq_MaritalStatus <- dados %>%
  count(MaritalStatus) %>% # Conta a frequência absoluta
  mutate(freq_rel_MaritalStatus = (n / sum(n))*100) # Calcula a frequência relativa
```

```
tab_freq_MaritalStatus
```

```
#Gráfico de setores do estado civil dos clientes
pie(table(dados$MaritalStatus),
  main = 'Gráfico de setores do estado civil dos clientes',
  radius = 1.0
)
```

```
#library(dplyr)
```

```
#Análise da frequência absoluta e relativa dos dias que os clientes pretendem usar as esteiras:
freq_abs_Usage <- table(dados$Usage)
freq_abs_Usage
round(((freq_abs_Usage)/180)*100,2)
```

```
#Análise da frequência absoluta e relativa dos dias que os clientes pretendem usar as esteiras:
tab_freq_Usage <- dados %>%
  count(Usage) %>% # Conta a frequência absoluta
  mutate(freq_rel_Usage = (n / sum(n))*100) # Calcula a frequência relativa
```

```
tab_freq_Usage
```

```
#Análise da frequência absoluta e relativa da autoavaliação física dos clientes:
```

```
tab_freq_Fitness <- dados %>%
```

```
  count(Fitness) %>% # Conta a frequência absoluta
```

```
  mutate(freq_rel_Fitness = (n / sum(n))*100) # Calcula a frequência relativa
```

```
tab_freq_Fitness
```

```
#Informações sintetizadas da base de dados
```

```
summary(dados)
```

```
#Função para calcular a moda das variáveis da base de dados:
```

```
calcular_moda <- function(x) {
```

```
  valores_unicos <- unique(x) #agrupa todos os valores aparecem
```

```
  frequencia <- tabulate(match(x, valores_unicos)) #Identifica a frequencia dos valores que aparecem
```

```
  valores_unicos[which.max(frequencia)] #identifica o indice do numero que mais aparece e retorna  
  seu valor
```

```
}
```

```
#Observação sobre a função calcular_moda: Ela não necessariamente identifica o valor que mais  
aparece, podem ocorrer empates!
```

```
#Calculando as modas das variáveis
```

```
moda_Product <- calcular_moda(dados$Product)
```

```
moda_Age <- calcular_moda(dados$Age)
```

```
moda_Gender <- calcular_moda(dados$Gender)
```

```
moda_Education <- calcular_moda(dados$Education)
```

```
moda_MaritalStatus <- calcular_moda(dados$MaritalStatus)
```

```
moda_Usage <- calcular_moda(dados$Usage)
```

```
moda_Fitness <- calcular_moda(dados$Fitness)
```

```
moda_Income <- calcular_moda(dados$Income)
```

```
moda_Miles <- calcular_moda(dados$Miles)
```

```
#Dataframe das modas
```

```
moda <- data.frame(
```

```
  Colunas = c('Product', 'Age', 'Gender', 'Education', 'MaritalStatus',  
              'Usage', 'Fitness', 'Income', 'Miles'),
```

```
  Modas = c('TM195', 25, 'Male', 16, 'Partnered', 3, 3, 45480, 85)
```

```
)
```

```
### Análise Bivariada dos Dados ###
```

```
#Tabela de produto por número de dias que o cliente planeja utilizar a esteira
```

```
table(dados$Product,dados$Usage)
```

```
#Tabela de produto por autoavaliação de aptidão física do cliente
```

```
table(dados$Product,dados$Fitness)
```

```
### Análise Multivariada dos Dados ###
```

```
#Boxplot da distribuição de Idade
```

```
boxplot(dados$Age,  
        main = "Boxplot das Idades",  
        ylab = "Anos de idade",  
        xlab = "Idade", col = c("red"))
```

```
#Boxplot da distribuição Education
```

```
boxplot(dados$Education,  
        main = "Boxplot da distribuição da variável Education",  
        ylab = "Anos de Estudo",  
        xlab = "Education", col = c("blue"))
```

```
#Boxplot da distribuição Usage
```

```
boxplot(dados$Usage,  
        main = "Boxplot da distribuição da variável Usage",  
        ylab = "Dias médios da semana",  
        xlab = "Usage", col = c("yellow"))
```

```
#Boxplot da distribuição Fitness
```

```
boxplot(dados$Fitness,  
        main = "Boxplot da distribuição da variável Fitness",  
        ylab = "Autoavaliação",  
        xlab = "Fitness", col = c("pink"))
```

```
#Boxplot da distribuição Income
```

```
boxplot(dados$Income,  
        main = "Boxplot da distribuição da variável Income",  
        ylab = "Renda Familiar",  
        xlab = "Income", col = c("tomato"))
```

```
options(scipen = 999)
```

```
#Boxplot da distribuição Miles
```

```
boxplot(dados$Miles,  
        main = "Boxplot da distribuição da variável Miles",  
        ylab = "Milhas",  
        xlab = "Miles", col = c("lightcoral"))
```

```
# Calculando a frequência por faixa de idade
```

```
dados$Faixa_Idade <- cut(dados$Age,  
                        breaks = c(18, 22, 26, 30, 34, 38, 42, 46, 50),  
                        labels = c("18-21", "22-25", "26-29", "30-33", "34-37", "38-41", "42-45", "46-50"),  
                        right = TRUE)
```

```

frequencia_faixa <- table(dados$Faixa_Idade)
print(frequencia_faixa)
barplot(frequencia_faixa,
        main = "Distribuição de frequência por Idade de cliente",
        ylab = "No. de clientes",
        xlab = "Idades",
        col = "green4")
)

#teste Anova
anova_resultado <- aov(Income ~ Product, data = dados)
summary(anova_resultado)

# Grafico boxplot relacionado a anova
dados$Product <- factor(dados$Product, levels = unique(dados$Product))
plot(dados$Product, dados$Income,
     main = "Gráfico da Renda Familiar por Esteira",
     xlab = "Esteira",
     ylab = "Renda Anual",
     col = c("tan", "olivedrab", "darkslateblue"),
     pch = 19,
     xaxt = "n")

axis(1, at = 1:length(levels(dados$Product)), labels = levels(dados$Product))

#Histograma renda anual
options(scipen = 999)
hist(dados$Income,
     main = "Distribuição de Renda",
     xlab = "Renda Anual",
     ylab = "Frequência",
     col = "tomato",
     breaks = 25,)

#Histograma distancia em milhas
hist(dados$Miles,
     main = "Distribuição de Distância Percorrida Em Milhas",
     xlab = "Distância (Miles)",
     ylab = "Frequência",
     col = "lightcoral",
     breaks = 25,
     freq = FALSE)
lines(density(dados$Miles), col = "black", lwd = 2)

#Histograma distancia em Km

```

```

dados$Kilometros <- dados$Miles * 1.60934
hist(dados$Kilometros,
     main = "Distribuição de Distância Percorrida Em Kilometers",
     xlab = "Distância (Km)",
     ylab = "Frequência",
     col = "lightseagreen",
     breaks = 25,
     freq = FALSE)
lines(density(dados$Kilometros), col = "black", lwd = 2)

```

```

#Gráfico estado civil e gênero
crosstab <- table(dados$Gender, dados$MaritalStatus)
print(crosstab)
barplot(crosstab,
       beside = TRUE,
       main = "Distribuição de Consumidores por estado civil e gênero",
       xlab = "Estado Civil",
       ylab = "Frequência",
       col = c("lightcoral", "lightblue"),
       legend.text = rownames(crosstab),
       args.legend = list(title = "Gênero", x = "topright"))
)

#Gráfico faixa etária por tipo de esteira
dados$AgeGroup <- cut(dados$Age, breaks = c(18, 25, 35, 45, 50),
                     labels = c("18-25", "26-35", "36-45", "46-50"))
table(dados$AgeGroup, dados$Product)
barplot(table(dados$AgeGroup, dados$Product),
       beside = TRUE,
       col = c("lightblue", "lightcoral", "lightgreen", "lightyellow"),
       main = "Distribuição de Compras por Faixa Etária e Produto",
       xlab = "Faixa Etária",
       ylab = "Número de Compras",
       legend.text = levels(dados$AgeGroup),
       args.legend = list(title = "Faixa Etária", x = "topright"))

```